# МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ (НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Компьютерные науки и прикладная математика» Кафедра 806 «Вычислительная математика и программирование»

# Лабораторная работа №5 по курсу «Программирование графических процессоров»

Сортировка чисел на GPU. Свертка, сканирование, гистограмма.

Выполнил: А.С. Федоров

Группа: 8О-407Б

Преподаватели: К.Г. Крашенинников,

А.Ю. Морозов

#### **Условие**

**Цель работы.** Ознакомление с фундаментальными алгоритмами GPU: свертка (reduce), сканирование (blelloch scan) и гистограмма (histogram). Реализация одной из сортировок на CUDA. Использование разделяемой и других видов памяти. Исследование производительности программы с помощью утилиты nvprof.

Вариант задания. 8. Поразрядная сортировка.

# Программное и аппаратное обеспечение

# Графический процессор

Название: NVIDIA GeForce GTX 1050

Compute capability: 6.1

Объем графической памяти: 2147352576 байтов Объем разделяемой памяти на блок: 49152 байтов

Объем регистров на блок: 65536

Размер варпа: 32

Максимальное количество потоков на блок: (1024, 1024, 64) Максимальное число блоков: (2147483647, 65535, 65535)

Объем постоянной памяти: 65536 байтов

Число мультипроцессоров: 5

#### Процессор

Название: i5-8250U

Базовая тактовая частота процессора: 1,60 ГГц

Количество ядер: 4 Количество потоков: 8

Кеш L1: 256 Кб Кеш L2: 1 Мб Кеш L3: 6 Мб

#### Оперативная память

Тип: DDR4 Объем: 11.9 Гб

Частота: 2400 МГц

#### Програмное обеспечение

OC: WSL2 (Windows 11)

IDE: Microsoft Visual Studio 2022 (аддон NVIDIA Nsight)

Компилятор: nvcc

# Метод решения

Поразрядная сортировка по битам осуществляется итерационно. Начиная с первого и заканчивая 32-м битом числа. На каждой итерации посчитываются исключающие префиксные суммы для текущего бита и на их основе выполняется устойчивая сортировка тоже по текущему биту. Так как значение бита может быть ноль или один, сортировку можно свести к простому правилу: если текущий бит числа равен нулю, то его новая позиция — это i - s[i], где i — изначальная позиция, а s[i] — i—ое значение префиксной суммы, иначе новая позиция — это s[i] + (n - s[n]), где n -число элементов в массиве, а s[n] — сумма всех текущих битов чисел.

# Описание программы

Алгоритм сортировки реализован в виде функции, которая вызывает в цикле следующие ядра: ядро вычисления значений битов для элементов массива за сохранение их в массив типа bool, ядро копирования этого массива, функция scan, которая внутри себя вызывает еще ядра, сортировка элементов массива по правилу, описанному выше. Во время сортировки поддерживается два массива: расположение элементов на прошлой итерации и новое положение.

Результат профилировки программы на тесте размером в 10<sup>6</sup>:

Invocations	Event Name	Min	Max	Avg	Total					
	DIA GeForce GTX 1050 (0)"									
Kernel:	scan_blocks_kernel(unsigned int*, unsigned	d int∗, unsign	ed int)							
96	divergent_branch	0	0	0	Θ					
96	shared_ld_bank_conflict	0	0	0	Θ					
96	shared_st_bank_conflict	0	Θ	0	Θ					
96	global_load	4	31252	10501	1008128					
96	global_store	8	62504	21002	2016256					
96	l2_subp0_write_sector_misses	0	62417	20811	1997920					
Kernel:	<pre>binary_digit_sort_kernel(unsigned int*, bo</pre>	ool*, unsigned	int*, unsign	ed int, uns:	igned int*)					
32	divergent_branch	0	0	0	Θ					
32	shared_ld_bank_conflict	0	0	0	Θ					
32	shared_st_bank_conflict	0	0	0	Θ					
32	global_load	125000	125000	125000	4000000					
32	global_store	31250	31250	31250	1000000					
32	l2_subp0_write_sector_misses	62736	64537	63017	2016566					
	Kernel: s_gen_kernel(bool*, unsigned int, unsigned int*)									
32	divergent_branch	0	0	0	Θ					
32	shared_ld_bank_conflict	0	0	0	Θ					
32	shared_st_bank_conflict	0	0	0	Θ					
32	global_load	31250	31250	31250	1000000					
32	global_store	31250	31250	31250	1000000					
32	l2_subp0_write_sector_misses	62003	62095	62044	1985420					
	rnel: add_kernel(unsigned int*, unsigned int*, unsigned int)									
64	divergent_branch	0	0	0	0					
64	shared_ld_bank_conflict	0	0	0	0					
64	shared_st_bank_conflict	0	0	0	0					
64	global_load	488	62496	31492	2015488					
64	global_store	244	31248	15746	1007744					
64	l2_subp0_write_sector_misses	0	62032	31006	1984435					
	<pre>b_gen_kernel(unsigned int*, unsigned int,</pre>	unsigned int,								
32	divergent_branch	0	0	Θ	0					
32	shared_ld_bank_conflict	0	0	Θ	0					
32	shared_st_bank_conflict	0	0	Θ	0					
32	global_load	31250	31250	31250	1000000					
32	global_store	31250	31250	31250	1000000					
32	l2_subp0_write_sector_misses	16581	17133	17003	544123					

Конфликтов банков памяти нет.

#### Код алгоритма blelloch scan:

```
const uint BLOCK SIZE = 128;
const uint LOG2_BLOCK_SIZE = 7;
const uint GRID_SIZE = 64;
 global__ void scan_blocks_kernel(uint* data, uint* sums, uint sums_size) {
    int blockId = blockIdx.x;
    while (blockId < sums_size) {</pre>
        extern __shared__ uint temp[];
        temp[_index(threadIdx.x)] = data[blockDim.x * blockId + threadIdx.x];
        __syncthreads();
        uint stride = 1;
        for (uint d = 0; d < LOG2_BLOCK_SIZE; ++d) {</pre>
            if ((threadIdx.x + 1) % (stride<<1) == 0) {</pre>
                temp[_index(threadIdx.x)] += temp[_index(threadIdx.x-stride)];
            stride <<= 1;</pre>
            __syncthreads();
            sums[blockId] = temp[_index(BLOCK_SIZE - 1)];
            temp[_index(BLOCK_SIZE - 1)] = 0;
        __syncthreads();
        stride = 1 << LOG2 BLOCK SIZE-1;</pre>
        while (stride != 0) {
            if ((threadIdx.x + 1) % (stride<<1) == 0) {</pre>
                uint tmp = temp[_index(threadIdx.x)];
                temp[_index(threadIdx.x)] += temp[_index(threadIdx.x - stride)];
            stride >>= 1;
            __syncthreads();
        data[blockDim.x * blockId + threadIdx.x] = temp[_index(threadIdx.x)];
        blockId += gridDim.x;
```

```
global void add_kernel(uint* data, uint* sums, uint sums_size) {
   uint blockId = blockIdx.x+1;
       if (blockId != 0) {
            data[blockDim.x * blockId + threadIdx.x] += sums[blockId];
       blockId += gridDim.x;
void scan(uint* dev_data, uint size) {
   if (size % BLOCK SIZE != 0)
        size += BLOCK_SIZE - (size % BLOCK_SIZE);
   uint sums_size = size/BLOCK_SIZE;
   uint* dev_sums;
   CSC(cudaMalloc(&dev_sums, (sums_size * sizeof(uint))));
   scan_blocks_kernel << < GRID_SIZE, BLOCK_SIZE, _index(BLOCK_SIZE) * sizeof(uint)</pre>
>> > (dev data, dev sums, sums size);
   CSC(cudaGetLastError());
   if (size <= BLOCK_SIZE)</pre>
   add_kernel << < GRID_SIZE, BLOCK_SIZE >> > (dev_data, dev_sums, sums_size);
   CSC(cudaGetLastError());
```

# Результаты (в миллисекундах)

	Размер теста (по вертикали и горизонтали)								
	10 <sup>2</sup>	10 <sup>3</sup>	10 <sup>4</sup>	105	10 <sup>6</sup>	10 <sup>7</sup>			
GPU(CUDA) <1, 32>	10.850	5.356	32.155	279.678	2657.003	25989.757			
GPU(CUDA) <32, 32>	3.450	2.729	13.493	15.485	114.099	938.435			
GPU(CUDA) <64, 32>	2.598	2.684	6.326	10.552	64.897	540.955			
GPU(CUDA) <64, 64>	4.294	2.869	4.296	7.806	45.551	353.679			
GPU(CUDA) <128, 64>	3.148	3.303	4.785	11.233	33.200	250.957			
GPU(CUDA) <128, 128>	1.557	11.398	10.950	6.462	36.288	275.310			
GPU(CUDA) <256, 128>	6.685	4.495	3.068	7.048	35.299	283.017			
CPU	0.051	0.509	5.182	51.356	531.957	5219.426			

#### Выводы

Алгоритм сортировки имеет применение практически везде, где есть программирование в принципе. Распараллеливание данной задачи на GPU может быть особенно полезно, если сортировку необходимо выполнить на очень большом объеме данных. В ходе реализации основной сложностью была реализация алгоритма blelloch scan. Также для прохождения ограничений по времени и по памяти были сделаны некоторые доработки. Было реализовано быстро целочисленное деление и умножение на два и хранение битов как bool.

Судя по результатам тестирования распараллеливание на большее число потоков и блоков дает хороший прирост по скорости практически на всех размерах тестируемых данных. Как и ожидалось, CPU работает быстрее на маленьких данных, но начинает сильно проигрывать на больших. Для тестов размером  $10^6$  и  $10^7$  ускорения после варианта в 128 блоков и 64 потока нет. Видимо потоков становится достаточно, чтобы на каждый элемент пришлось по одному.